

OPERATOR AND ADMINISTRATOR GUIDE

คู่มือการแบ่งชุดข้อมูล Train / Val / Test

การจัดกลุ่มภาพตามชิ้นงานและช่วงเวลาถ่ายภาพ เพื่อลด data leakage พร้อมระบบ preview, manifest, quarantine และ Undo

ระบบ

Ai-JIN Platform

โมดูล

Data Import

ฉบับ

1.0 / 22 กรกฎาคม 2026

Environment

D:\Ai-JIN_Platform

สารบัญ

01	วัตถุประสงค์และขอบเขตโฟลเดอร์	2
02	เปิดหน้า Import และตั้งค่า split	3
03	Analyze Split และอ่านผล Preview	4
04	Apply และผลจริงของ Dataset	5
05	สร้าง Dataset YAML	6
06	Undo, Manifest และการกู้คืน	7
07	มือถือและเกณฑ์พร้อม Train	8
08	การแก้ปัญหาและ API	9
09	Checklist ส่งมอบ	10

ขอบเขตระบบ

Ai-JIN Platform

D:\Ai-JIN_Platform
Web UI, annotation, dataset, training, inference, models
และ API

App AI Camera

D:\Ai-JIN_V10.0_patch_output
PyQt5 camera, tracking, counting, PLC และ production
runtime

Platform legacy archive

D:\Ai-JIN_Platform\legacy\v10-platform-stack-20260722
เก็บ Platform เดิมที่ย้ายออกจาก App AI Camera เพื่ออ้างอิงและย้อนตรวจ ไม่ใช่ runtime หลัก

กฎสำคัญ: ห้ามนำโค้ดหรือ runtime data ของ Platform กลับไปเก็บในโฟลเดอร์ App AI Camera

1. เปิดหน้า Import

1. เปิด Chrome และเข้า <http://localhost:8501/import>
2. เลื่อนไปหัวข้อ สถิติชุดข้อมูล
3. ตรวจสอบจำนวน Images, Labels และ Label coverage ของทุก split
4. ใส่ค่า 80 / 10 / 10, Session gap 30 วินาที และ Seed 42

สถิติชุดข้อมูล

1303 รูป

Train / Val / Test พร้อมการแยกกลุ่มตามช่วงเวลาถ่ายภาพ

TRAIN

รูปภาพ 1249

Labels 1

Label coverage 0.1%

VAL

รูปภาพ 54

Labels 0

Label coverage 0.0%

TEST

รูปภาพ 0

Labels 0

Label coverage 0.0%

จัดสัดส่วนชุดข้อมูล

ค่าเริ่มต้น 80 / 10 / 10 - Seed เดิมให้ผลซ้ำได้

ไป Analyze Split

TRAIN (%)

80

VAL (%)

10

TEST (%)

10

Session gap (sec)

30

Seed

42

ภาพจริงที่ 1 - สถิติ Train / Val / Test และชุดควบคุม Analyze Split

ค่าที่แนะนำ

ค่า	แนะนำ	ความหมาย
Train / Val / Test	80 / 10 / 10	รวมกันต้องเท่ากับ 100%
Session gap	30 sec	ช่วงสูงสุดที่ภาพ workpiece เดียวกันยังเป็นกลุ่มเดียวกัน
Seed	42	ทำให้การจัดกลุ่มซ้ำได้ผลเดิม

ก่อนเริ่ม: หยุด upload, annotate และ train ที่กำลังเขียน dataset ชุดเดียวกัน

2. วิเคราะห์ก่อนย้ายไฟล์

1. Scan

อ่านภาพและ label

2. Hash

ตรวจ exact duplicate

3. Group

รวมภาพตามเวลา

4. Assign

จัด Train/Val/Test

5. Preview

ยังไม่ย้ายไฟล์

สถิติชุดข้อมูล 1303 รูป

Train / Val / Test พร้อมการแยกกลุ่มตามช่วงเวลาถ่ายภาพ

TRAIN
รูปภาพ 1249
Labels 1
Label coverage 0.1%

VAL
รูปภาพ 54
Labels 0
Label coverage 0.0%

TEST
รูปภาพ 0
Labels 0
Label coverage 0.0%

จัดสัดส่วนชุดข้อมูล Analyze Split
ค่าเริ่มต้น 80 / 10 / 10 - Seed เดิมให้ผลลัพธ์ได้

TRAIN (%)
80

VAL (%)
10

TEST (%)
10

Session gap (sec)
30

Seed
42

ผลวิเคราะห์ก่อน Apply Plan 20260722_181429_3bbdee64
320 กลุ่ม - 1249 รูปไม่ซ้ำ

TRAIN 1015

VAL 127

TEST 107

DUPLICATES 54

WORKPIECE	TOTAL	GROUPS	TRAIN	VAL	TEST	LABELS
F-373130-K010	270	4	234	27	9	1
JBA-22-000050	270	18	214	29	27	0
JBA-24-000060	169	116	135	17	17	0
JBA-24-000070	270	103	216	27	27	0
S-156-061520P	270	79	216	27	27	0

Only 1/1249 canonical images have label files

54 exact duplicate images will be quarantined

ย้ายภาพ 234 - ย้าย labels 1 ✓ Apply Split

ภาพจริงที่ 2 - Preview แสดง proposed totals, groups, file moves และคำเตือน

Canonical images

ภาพไม่ซ้ำที่ถูกนำไปจัด split

Exact duplicates

ภาพซ้ำที่ย้ายไป quarantine โดยไม่ลบทิ้ง

Capture groups

กลุ่มภาพต่อเนื่องที่จะไม่ถูกแยกข้าม split

Moves

จำนวน image/label ที่แผนจะย้ายจริง

3. Apply Split

ตรวจตาราง workpiece และค่าเตือนแล้วกด **Apply Split** จากนั้นยืนยันจำนวนไฟล์ ระบบจะตรวจ SHA และตำแหน่งต้นทางซ้ำก่อนย้ายจริง

สถิติชุดข้อมูล

1249 รูป

Train / Val / Test พร้อมการแยกกลุ่มตามช่วงเวลาถ่ายภาพ

TRAIN

รูปภาพ 1015
Labels 0
Label coverage 0.0%

VAL

รูปภาพ 127
Labels 0
Label coverage 0.0%

TEST

รูปภาพ 107
Labels 1
Label coverage 0.9%

จัดสัดส่วนชุดข้อมูล

ค่าเริ่มต้น 80 / 10 / 10 - Seed เดิมให้ผลซ้ำได้

Analyze Split

TRAIN (%) 80

VAL (%) 10

TEST (%) 10

Session gap (sec) 30

Seed 42

Split ล่าสุดพร้อมย้อนกลับ

20260722_181429_3bbdee64

Undo

ภาพจริงที่ 3 - สถานะหลัง Apply พร้อม manifest และปุ่ม Undo

TRAIN	VAL	TEST
1,015	127	107
81.3% / Labels 0	10.2% / Labels 0	8.6% / Labels 1

ผลตรวจ: 1,249 canonical images, 320 capture groups, 0 duplicate hash ซ้ำ split, 0 group leakage และ 54 duplicate images ใน quarantine

Manifest ที่ใช้งาน

20260722_181429_3bbdee64

ยังไม่พร้อม Train: label coverage รวมเพียง 1 / 1,249 ภาพ ต้อง annotate และตรวจคุณภาพกรอบก่อน

Dataset Split Guide v1.0

5 / 10

4. สร้างไฟล์ data.yaml

1. เลื่อนไปหัวข้อ สร้างไฟล์ตั้งค่า Dataset
2. กด สร้าง YAML
3. ตรวจสอบ path จากข้อความยืนยัน
4. เปิดไฟล์และตรวจสอบ train, val, test, nc และ names



ภาพจริงที่ 4 - ยืนยัน data.yaml ใน runtime path ของ Platform

ตำแหน่งไฟล์

D:\Ai-JIN_Platform\dataset\auto_improve\data.yaml

คลาสที่ระบบค้นพบ (nc = 5)

F-373130-K010

JBA-22-000050

JBA-24-000060

JBA-24-000070

S-156-061520P

Runtime paths

Dataset	D:\Ai-JIN_Platform\dataset
Training runs	D:\Ai-JIN_Platform\runs
Models	D:\Ai-JIN_Platform\models

5. Undo อย่างปลอดภัย

1. หยุดงานที่กำลังเขียน dataset
2. เปิดหน้า Import และตรวจ manifest ล่าสุด
3. กด **Undo** แล้วอ่านรายการที่จะย้อนกลับ
4. ยืนยัน และรอให้ระบบคืน image, label และ duplicate จาก quarantine
5. รีเฟรชและตรวจจำนวนไฟล์ทั้งสาม split

Manifest

dataset\auto_improve\split_manifests
บันทึกต้นทาง ปลายทาง SHA และสถานะ transaction

Quarantine

dataset\auto_improve\split_quarantine\
<manifest_id>
เก็บ exact duplicates เพื่อให้ตรวจสอบหรือ Undo ได้


กลไกป้องกันข้อมูล

เหตุการณ์	พฤติกรรมระบบ
Dataset เปลี่ยนหลัง Preview	หยุด Apply และตอบ 409 stale plan
ปลายทางมีไฟล์ชื่อเดียวกัน	หยุดก่อนเขียนทับและรายงาน conflict
SHA ต้นทางไม่ตรง	หยุด transaction เพื่อรักษาไฟล์เดิม
ย้ายบางส่วนแล้วเกิดข้อผิดพลาด	ใช้ operation log เพื่อ rollback

ห้าม: ลบ manifest/quarantine หรือย้าย dataset ด้วย Windows Explorer ก่อนยืนยันว่าไม่ต้อง Undo

6. ใช้งานบนมือถือ

หน้า Import ใช้เต็มความกว้าง แลบนำทางด้านบนเลื่อนในแนวนอนได้ และซ่อน sidebar บนหน้าจอแคบ



ภาพจริงที่ 5 - Chrome 430 x 900

7. พร้อม Train หรือไม่

- ☐ ทุกภาพที่ใช้มี YOLO label ถูกต้อง
- ☐ กรอบขีดชั้นงานและ class ถูกต้อง
- ☐ Train และ Val มี label coverage เพียงพอ
- ☐ ไม่มี hash หรือ capture group รั่วข้าม split
- ☐ ทุก class มีตัวอย่างเพียงพอใน Train/Val
- ☐ Test ไม่ถูกใช้รับค่าโมเดล
- ☐ data.yaml มี path และ names ถูกต้อง

สถานะปัจจุบัน: ไม่พร้อม

มี label 1 ไฟล์จาก 1,249 ภาพ และ label นั้นอยู่ใน Test

แนะนำให้ใช้จอตส์ก์ที่อปเมื่อ Apply หรือ Undo เพื่ออ่านตาราง workpiece และค่าเตือนได้ครบถ้วน

8. การแก้ปัญหา

อาการ	แนวทางแก้ไข
400 Bad Request	ตั้ง Train + Val + Test ให้รวม 100 และทุกค่ามากกว่า 0
409 Conflict	Dataset เปลี่ยนหลัง Analyze ให้รีเฟรชและ Analyze ใหม่
500 Internal Server Error	ตรวจ Platform log, path และ permission โดย path ต้องอยู่ใต้ D:\Ai-JIN_Platform
Apply ไม่สำเร็จ	ปิดโปรแกรมที่ล็อกไฟล์ แล้ว Analyze ใหม่
YAML มี nc = 0	ตรวจสอบชื่อ workpiece folders/filenames แล้วสร้าง YAML ใหม่
Train ไม่มี label	Annotate และตรวจ label ก่อนเริ่ม Train

9. API สำหรับผู้ดูแล

Method	Endpoint	หน้าที่
GET	/api/import/split-info	สถิติ dataset
POST	/api/import/split/preview	สร้างแผนโดยไม่ย้ายไฟล์
POST	/api/import/split/apply	ตรวจ preflight และ Apply
GET	/api/import/split/latest	อ่าน manifest ล่าสุด
POST	/api/import/split/undo	ย้อนกลับ manifest
POST	/api/import/generate-yaml	สร้าง data.yaml

10. Checklist ผู้ปฏิบัติงาน

ก่อน Analyze

- ☐ เปิดหน้า /import ถูกระบบ
- ☐ หยดงานที่เขียน dataset
- ☐ ตรวจสอบสถิติและ label coverage
- ☐ กำหนด 80 / 10 / 10, gap 30, seed 42

ก่อน Apply

- ☐ อ่าน warning ทุกบรรทัด
- ☐ ตรวจสอบ workpiece breakdown
- ☐ ตรวจสอบ duplicate และจำนวน moves
- ☐ ยืนยันว่าไม่มี upload/annotate พร้อมกัน

หลัง Apply

- ☐ บันทึก manifest ID
- ☐ ตรวจสอบ Train / Val / Test counts
- ☐ สร้างและเปิด data.yaml
- ☐ เก็บ manifest และ quarantine

ก่อน Train

- ☐ Label coverage เพียงพอ
- ☐ กรอบและ class ผ่าน QA
- ☐ แต่ละ class มี Train/Val
- ☐ Test ถูกกันออกจาก tuning

สถานะการตรวจรับ

Dataset canonical images	1,249
Split result	1,015 / 127 / 107
Cross-split duplicate SHA	0
Capture-group leakage	0
Browser console	0 errors / 0 warnings
Train readiness	ไม่ผ่าน - ต้อง annotate เพิ่ม

เอกสารอ้างอิง: docs/platform-boundary.md

คู่มือฉบับแก้ไข: docs/manual/Ai-JIN-Platform-Dataset-Split-Guide-TH.md